

## Planul cursului

- 1. Introducere
- 2. Modelul de regresie liniară simplă
- 3. Modelul de regresie liniară multiplă
- 4. Modele de regresie neliniară
- 5. Ipoteze statistice: normalitatea erorilor, homoscedasticitatea, necorelarea erorilor, multicoliniaritatea.

# 5. Verificarea ipotezelor modelului de regresie

Ipotezele statistice care se formulează în modelarea econometrică sunt ipoteze asupra componentei aleatoare (erorilor) și ipoteze asupra componentei deterministe (variabilelor independente).

- **5.1.** Ipotezele asupra componentei aleatoare (erorilor) sunt următoarele:
- a. Media erorilor este nulă:  $M(\varepsilon_i) = 0$ .
- b. Ipoteza de homoscedasticitate:  $V(\varepsilon_i) = \sigma^2$
- c. Ipoteza de normalitate:  $\varepsilon_i \sim N(0, \sigma^2)$

# 5. Verificarea ipotezelor modelului de regresie

Ipoteza de necorelare sau de independență a erorilor:  $cov(\varepsilon_{i}, \varepsilon_{i})=0$ .

### 5.2. Ipotezele asupra variabilelor independente

- a. Variabilele independente sunt nestochastice sau deterministe.
- b. Variabilele independente și variabila eroare sunt necorelate,  $cov(X_i, \varepsilon_i)=0$ .
- c. Ipoteza de necoliniaritate a variabilelor independente.

### 5.1. Ipotezele asupra componentei aleatoare (erorilor)

### a. Media erorilor este nulă

**1. Definire**:  $M(\varepsilon_i) = 0$  care este echivalentă cu  $M(Y/X) = \beta_0 + \beta_1 X$ .

### 2. Efectele încălcării acestei ipoteze:

dacă această ipoteză este încălcată, atunci se modifică proprietățile estimatorilor parametrilor modelului de regresie (parametrii sunt estimați deplasat sau cu o eroare sistematică).

### 3. Testarea ipotezei cu privire la media erorilor

□Ipoteze:

$$H_0: M(\varepsilon) = 0$$

$$H_1$$
:  $M(\varepsilon)$ #0

□Alegerea testului:

$$t = \frac{\hat{M}(\varepsilon) - M(\varepsilon)}{\sqrt{\hat{V}(\hat{M}(\varepsilon))}}$$

Calculul statisticii test:  $t_{calc} = \frac{W(e_i)}{S_{\hat{M}(\epsilon_i)}}$ 

□ Decizie

### 4. Exemplu

#### Residuals Statistics<sup>a</sup>

	Minimum	Maximum	Mean	Std. Deviation	N
Predicted Value	58508,12	6084511	1582428	1957596,554	15
Residual	-98125,2	131202,7	,00000	73271,63549	15
Std. Predicted Value	-,778	2,300	,000	1,000	15
Std. Residual	-1,290	1,725	,000	,964	15

a. Dependent Variable: salariu

### **One-Sample Statistics**

				Std. Error	
	N	Mean	Std. Deviation	Mean	
Unstandardized Residual	15	,0000000	73271,63549	18918,65	

### **One-Sample Test**

		Test Value = 0					
					95% Coi Interva	l of the	
				Mean	Difference		
	t	df	Sig. (2-tailed)	Difference	Lower	Upper	
Unstandardized Residual	,000	14	1,000	,00000000	-40576,5	40576,48	

### 5. Corectarea modelului

- □ Modelul inițial se corectează cu ajutorul estimației erorilor calculate la nivelul eșantionului.
- Modelul corectat este de forma:

$$y_i^* = \beta_0 + \beta_i x_i + u_i$$
, unde:

$$y_i^* = y_i - M(\varepsilon_i)$$

### b. Ipoteza de homoscedasticitate a erorilor

### 1. Definire

- ipoteza de homoscedasticitate presupune ca varianța erorilor să fie constantă:

$$V(\varepsilon_i) = \sigma^2$$

- această ipoteză presupune o varianță constantă și egală a erorilor la nivelul distribuțiilor condiționate de forma

$$Y \mid X = x_i$$

## 2. Efectele încălcării acestei ipoteze

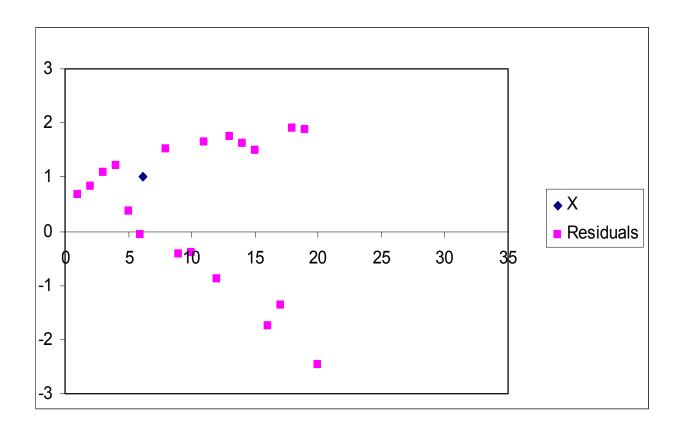
pierderea eficienței estimatorilor parametrilor modelului de regresie (estimează parametrul cu o varianță mai mare).

### 3. Identificarea heteroscedasticității

### 3.1. Procedee grafice

- presupun reprezentarea distribuției erorilor și aprecierea varianței acesteia.

## - cazul existenței heteroscedasticității:



### 3.2. Procedee numerice

## a. Testul Glejser (pentru modele simple)

are la bază un model de regresie între variabila reziduală estimată și variabila independentă.

### Etapele testării:

1. Se estimează modelul de regresie de forma:

$$Y = \beta_0 + \beta_1 \cdot X + \varepsilon$$

- 2. Se calculează erorile estimate  $e_i$ .
- 3. Se construiește un model de regresie pe baza erorilor estimate în valoare absolută și variabila

### a. Testul Glejser

independentă. Exemplu:

$$\left|\varepsilon_{i}\right| = \alpha_{0} + \alpha_{1} \cdot x_{i} + u_{i}$$

4. Se testează parametrii acestui model: dacă parametrul  $\alpha_1$  este semnificativ, atunci modelul inițial este heteroscedastic.

Exemplu:

## a. Testul Glejser

### Coefficientsa

			dardized cients	Standardized Coefficients			
Model		В	Std. Error	Beta	t	Sig.	
1	(Constant)	50921,663	12000,771		4,243	,001	
	PIB	,016	,012	,348	1,337	,204	

a. Dependent Variable: erori

## b. Testul Breusch-Pagan-Godfrey (pentru modele multiple)

este similar testului Glejser, cu excepția faptului că se consideră ca variabilă dependentă pătratul erorilor.

## b. Testul Breusch-Pagan-Godfrey (pentru modele multiple)

Heteroskedasticity Test: Breusch	n-Pagan-Godfrey			
F-statistic	0.991388	Prob. F(2,7)		0.4177
Obs*R-squared	2.207309	Prob. Chi-Square	` '	0.3317
Scaled explained SS	1.612479	Prob. Chi-Square	0.4465	
Test Equation:				
Dependent Variable: RESID^2				
Method: Least Squares				
Sample: 1 10				
Included observations: 10				
Variable	Coefficient	Std. Error t-Statisti		Prob.
C	-3.516496	658.6977	-0.005339	0.9959
X1	0.855525	2.856270	0.299525	0.7732
X2	-0.480219	3.606007	-0.133172	0.8978
R-squared	0.220731	Mean dependent v		44.96155
Adjusted R-squared	-0.001917	S.D. dependent va		81.83752
S.E. of regression	81.91594	Akaike info criter		11.89259
Sum squared resid	46971.55	Schwarz criterion		11.98336
Log likelihood	-56.46295	Hannan-Quinn cri		11.79301
F-statistic	0.991388	Durbin-Watson st	at	1.709325
Prob(F-statistic)	0.417740			

## 4. Corectarea heteroscedasticității

## 4.1. Dacă se cunosc parametrii $\sigma_i^2$

Corecția heteroscedasticității este aplicată modelului de regresie liniară simplă:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Corectarea heteroscedasticității presupune ponderarea modelului inițial cu variabila  $\frac{1}{\sigma_i}$ .

Noul model de regresie (corectat) se obține astfel:

$$\frac{y_i}{\sigma_i} = \frac{\beta_0}{\sigma_i} + \beta_1 \frac{x_i}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}$$

Estimarea parametrilor acestui model se realizează pe baza MCMMP ponderată (*method of weighted least squares*).

4.2. Dacă nu se cunosc parametrii  $\sigma_i^2$  Corecția heteroscedasticității se realizează pe baza relației:

$$\sigma_i^2 = \sigma^2 x_i^2$$

Corectarea heteroscedasticității presupune ponderarea modelului inițial cu variabila  $1/x_i$ .

Noul model de regresie (corectat) este de forma:

$$\frac{y_i}{x_i} = \frac{\beta_0}{x_i} + \beta_1 + \frac{\varepsilon_i}{x_i}$$

## c. Ipoteza de normalitate a erorilor

### 1. Formularea problemei

erorile  $\epsilon$  urmează o lege normală de medie 0 și varianță  $\sigma^2$ :

$$\varepsilon_i \sim N(0, \sigma^2)$$

### 2. Efectele încălcării acestei ipoteze

ipoteza de normalitate a erorilor este importantă pentru stabilirea proprietăților estimatorilor parametrilor modelului de regresie.

dacă  $\varepsilon_i \sim N(\theta, \sigma^2)$ , atunci estimatorii parametrilor modelului de regresie urmează, de asemenea, o lege normală:

$$\hat{\beta}_i \sim N(\beta_i, \sigma_{\hat{\beta}_i}^2)$$

dacă ipoteza de normalitate este încălcată, atunci estimatorii parametrilor modelului de regresie nu urmează o lege normală (pentru eșantioane de volum mare, proprietatea de normalitate este atinsă asimptotic).

## 3. Verificarea normalității erorilor

### 3.1. Procedee grafice

- Histograma (curba frecvenței):
- P-P Plot sau Q-Q Plot;
- Box-Plot.

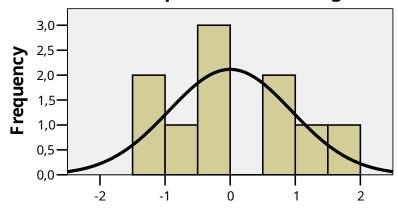
- a. Reprezentarea histogramei și a curbei frecvențelor
- se reprezintă curba frecvenței sau histograma reziduurilor și se observă dacă forma distribuției acestora are alură de clopot.

Exemplu:

## Histograma și curba frecvențelor

#### Histogram

### **Dependent Variable: greut**



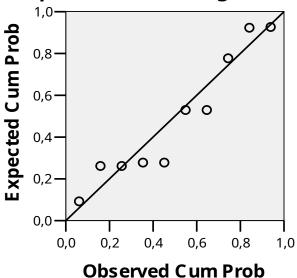
**Regression Standardized Residual** 

Mean = -1,85E-15 Std. Dev. = 0,943 N = 10

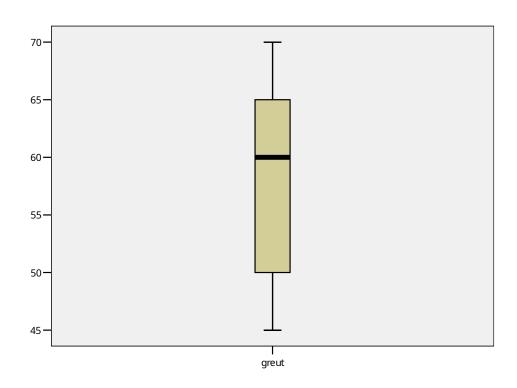
## b. P-P Plot sau Q-Q Plot

## Normal P-P Plot of Regression Standardized Residual

### **Dependent Variable: greut**



## c. Box-plot



## 3.2. Procedee numerice

### a. Testul Kolmogorov-Smirnov

- presupune compararea frecvențelor cumulate (calculate) cu frecvențele teoretice cumulate extrase din tabelul Gauss.

### *Ipoteze statistice*:

H<sub>0</sub>: ipoteza de normalitate

H<sub>1</sub>: distribuția erorilor nu urmează o lege normală

### Regula de decizie:

valoarea probabilității asociate statisticii test calculate (Sig.) se compară cu  $\alpha$  (0,05): dacă Sig.<0,05, atunci se respinge ipoteza de normalitate a erorilor.

Exemplu:

### **One-Sample Kolmogorov-Smirnov Test**

		greut
N		10
Normal Parameters a,b	Mean	58,5000
	Std. Deviation	7,83511
Most Extreme	Absolute	,276
Differences	Positive	,161
	Negative	-,276
Kolmogorov-Smirnov Z		,873
Asymp. Sig. (2-tailed)		,432

a. Test distribution is Normal.

b. Calculated from data.

## b. Testul Jarque-Bera

se bazează pe verificarea simultană a proprietăților de asimetrie și boltire ale seriei reziduurilor. Pentru o distribuție normală, valoarea coeficientului de asimetrie Fisher (*sw*) este zero, iar valoarea coeficientului de boltire Fisher (*k*) este zero.

### Ipoteze statistice

H<sub>0</sub>: ipoteza de normalitate

H<sub>1</sub>: distribuția erorilor nu urmează o lege normală

### Calculul statisticii test:

□ statistica test JB se calculează după relația:

$$JB = \frac{n}{6} \cdot \left( sw^2 + \frac{k^2}{4} \right)$$

unde: sw este coeficientul de asimetrie (Skewness):

$$sw = \frac{\mu_3}{\sigma^3}$$

k este coeficientul de boltire (Kurtosis):

$$k = \frac{\mu_4}{\mu_2^2} - 3$$

În cazul unui model de regresie, estimațiile celor doi parametri ai formei unei distribuții au următoarele relații:

$$sw = \sqrt{\frac{(\sum_{i} \frac{e_{i}^{3}}{n-2})^{2}}{(\sum_{i} \frac{e_{i}^{2}}{n-2})^{3}}}$$

$$k = \frac{\sum_{i} \frac{e_{i}^{4}}{n-2}}{(\sum_{i} \frac{e_{i}^{2}}{n-2})^{2}} - 3$$

unde:  $e_i = y_i - y_{x_i}$ 

Regula de decizie:

Statistica JB urmează o lege  $\chi^2_{\alpha,2}$ .

- dacă valoarea calculată a statisticii test JB >  $\chi^2_{\alpha;2}$  sau Sig.<0,05, atunci se respinge ipoteza Ho.

Exemplu.

### **Descriptive Statistics**

	N	Minimum	Maximum	Mean	Std.	Skewness		Kurtosis	
	Statistic	Statistic	Statistic	Statistic	Statistic	Statistic	Std. Error	Statistic	Std. Error
Unstandardized Residual	7	-2.61905	2.14286	.0000000	1.889822	529	.794	-1.375	1.587
Valid N (listwise)	7								