

CAPITOLUL 4

MODELE NELINIARE

4.1. INTRODUCERE

Pentru **modelele liniare**, viteza de variație a variabilei dependente în raport cu cea independentă este constantă pe întreg câmpul de variație a variabilei predictor.

Teoria și practica economică însă arată că modelele liniare nu sunt și cel mai frecvent utilizate. În multe situații, cercetarea impune apelul la **modele neliniare**, caz în care *variația variabilei dependente* nu depinde doar de variația variabilei independente, ci și de valoarea variabilei factoriale la care se înregistrează această variație.

Cu alte cuvinte, *viteza de variație a variabilei dependente* **nu mai este constantă**, ci depinde de valorile variabilei independente, de valorile variabilei dependente sau simultan de ambele.

Din punct de vedere econometric, aceste modele prezintă elemente specifice, atât în privința posibilităților de estimare a parametrilor, cât și de aplicare practică a modelelor.

În cele ce urmează, sunt prezentate o serie de modele de regresie neliniară care permit estimarea parametrilor prin **metoda celor mai mici pătrate** (MCMMP).

În această categorie se includ modelele care pot fi *liniarizabile*, de regulă, cu ajutorul funcției logaritm, dar și modele *neliniazabile*, precum cele polinomiale și cel reciproc.

1. Modele liniarizabile

1.1. Modele cu ambele variabile logaritmuate

- Modelul de tip putere simplu sau modelul log-liniar simplu
- Modelul de tip putere multiplu sau modelul log-liniar multiplu (Funcția de producție Cobb-Douglas)

1.2. Modele cu variabila independentă (X) logaritmată

- Modelul Logarithmic

1.3. Modele cu variabila dependentă (Y) logaritmată

- Modelul Compound (compus)
- Modelul Growth (de creștere)
- Modelul Exponential (exponențial)

2. Modele neliniazabile (modelele polinomiale)

2.1. Modelul Quadratic sau parabolic

2.2. Modelul cubic

Observație:

Pentru fiecare model în parte, trebuie să știți:

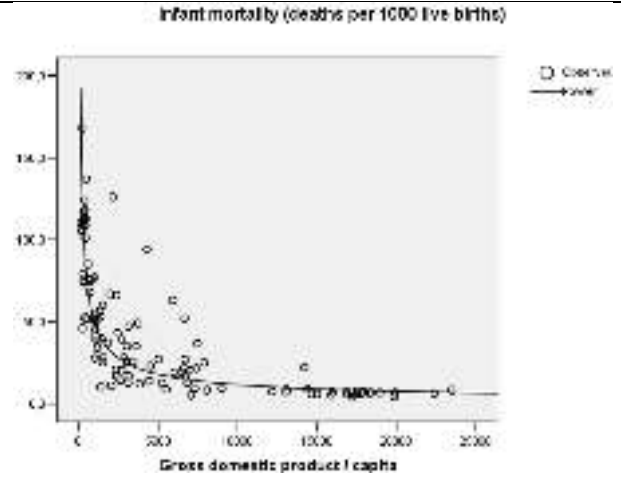
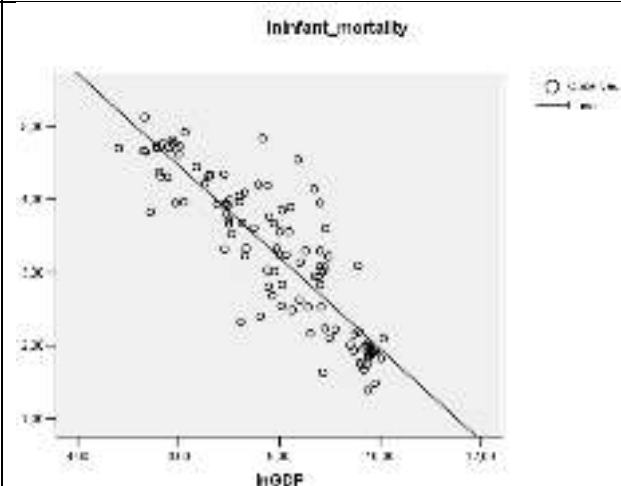
- identificarea modelului pe baza informațiilor din tabelul de coeficienți (pentru toate modelele) și pe baza reprezentărilor grafice (pentru modelele polinomiale);
- ecuația modelului neliniarizat și a modelului liniarizat prin funcția logaritm (pentru modelele care pot fi transformate cu ajutorul funcției logaritm sau liniarizate);
- ecuația estimată a modelului neliniarizat și a modelului liniarizat (scrisă atât teoretic, cât și pe baza estimațiilor coeficienților de regresie din tabelul *Coefficients*);
- restricțiile asupra componentelor fiecărui model (variabile și/sau parametri), precum și particularitățile corespunzătoare fiecărui model cu privire la interpretarea parametrilor;
- definirea parametrilor modelului (β_0 - ca medie; β_1 - ca raport de variații);
- interpretarea estimațiilor parametrilor modelului de regresie (b_0 ; b_1) – mare atenție la particularitățile corespunzătoare fiecărui model cu privire la interpretarea estimațiilor parametrilor modelului, adică la transformările aduse asupra estimațiilor b_0 și b_1 în funcție de fiecare model în parte.

4.2. MODELE LINIARIZABILE

Modelul log-liniar este un model neliniar în care variabilele apar prin funcția logaritm.

Relația dintre variabilele logaritmăte este de tip liniar (*modelul este liniar în parametri*), ceea ce permite utilizarea proprietăților modelelor liniare pentru estimarea și testarea parametrilor modelului.

Acest tip de model poate fi considerat un rezultat al procesului de liniarizare, cu ajutorul funcției logaritm aplicate unui model neliniar de tip putere.

1. MODELE LINIARIZABILE	1.1(a) Modelul de regresie cu ambele variabile logaritmăte (Y și X)	
	Modelul de tip putere (Power)	Modelul log-liniar (liniarizat)
Reprezentarea grafică		
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoare a variabilelor	Considerăm modelul de regresie cu două variabile (X, Y) de forma: $Y = \beta_0 X^{\beta_1} e^{\varepsilon}$ $y_i = \beta_0 x_i^{\beta_1} e^{\varepsilon_i}$	Prin logaritmare, se obține modelul: $\ln Y = \ln \beta_0 + \beta_1 \ln X + \varepsilon$ $\ln y_i = \ln \beta_0 + \beta_1 \ln x_i + \varepsilon_i$ Modelul obținut este un model log-liniar, adică un model de tip liniar, în care ambele variabile apar prin funcția logaritm.
Restricții și observații	Variabila dependentă Y are doar valori pozitive, așadar $\beta_0 > 0$. Variabila independentă X are doar valori pozitive. Parametrul $\beta_1 \in \mathbb{R}$, semnul indicând sensul legăturii dintre cele două variabile.	
Interpretarea coeficienților de regresie sau a	$\beta_0 = E(Y)_{ X=1} \Leftrightarrow \beta_0 = E(Y)_{ \ln X=0}$ Parametrul β_0 reprezintă <i>valoarea medie</i> a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 1 unitate .	

<p><i>parametrilor modelului</i></p>	$\beta_1 = \frac{d\ln Y}{d\ln X} = \frac{\frac{dY}{Y}}{\frac{dX}{X}}$ <p>Parametrul β_1 reprezintă raportul dintre variația medie relativă a variabilei dependente și variația relativă a variabilei independente. Această variație se poate exprima și procentual:</p> $\beta_{1(\%) } = d\ln Y_{(\%) } _{d\ln X = 1\%}$ <p>Exprimat în procente, $\beta_1 \%$ arată că la o creștere a variabilei independente (X) cu 1%, variabila dependentă (Y) variază, în medie, cu $\beta_1 \%$.</p>		
	<p>Viteza de variație a variabilei dependente în raport cu cea independentă nu este constantă, ci depinde și de valorile celor două variabile, adică de punctul în care se calculează. Aceasta reprezintă tangenta la curba de regresie în fiecare punct:</p> $\beta_1 = \frac{d\ln Y}{d\ln X} = \frac{\frac{dY}{Y}}{\frac{dX}{X}} = \frac{dY}{dX} \frac{X}{Y} \Rightarrow \frac{dY}{dX} = \beta_1 \frac{Y}{X}$ <p>Elasticitatea unei variabile Y în raport cu o altă variabilă X reprezintă modificarea relativă (procentuală) a variabilei Y la o modificare relativă (procentuală) dată a lui X, de obicei mică, de o unitate. Formalizând, elasticitatea E este dată prin relația:</p> $E = \frac{\% \text{modif } Y}{\% \text{modif } X} = \frac{\frac{\Delta Y}{Y}}{\frac{\Delta X}{X}} = \frac{\Delta Y}{\Delta X} \frac{X}{Y}$ <p>Unde Δ semnifică modificările sau diferențele realizate la nivelul unei variabile (operatorul diferențial).</p> $E = \frac{d\ln Y}{d\ln X} = \beta_1$ <p>Prin urmare, pentru modelul log-liniar, elasticitatea (E) este tocmai parametrul β_1 și este constantă. De aceea interpretarea parametrului β_1 se poate face și astfel: β_1 reprezintă și elasticitatea (E) variabilei dependente (Y) în raport cu variabila independentă (X).</p>		
<p><i>Ecuția estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare</i></p>	<table> <tr> <td> $Y_X = b_0 X^{b_1}$ $y_{x_i} = b_0 x_i^{b_1}$ </td><td> $\ln Y_X = \ln b_0 + b_1 \ln X$ $\ln y_{x_i} = \ln b_0 + b_1 \ln x_i$ </td></tr> </table>	$Y_X = b_0 X^{b_1}$ $y_{x_i} = b_0 x_i^{b_1}$	$\ln Y_X = \ln b_0 + b_1 \ln X$ $\ln y_{x_i} = \ln b_0 + b_1 \ln x_i$
$Y_X = b_0 X^{b_1}$ $y_{x_i} = b_0 x_i^{b_1}$	$\ln Y_X = \ln b_0 + b_1 \ln X$ $\ln y_{x_i} = \ln b_0 + b_1 \ln x_i$		

<i>valoarea a variabilelor</i>		
<i>Interpretarea estimațiilor parametrilor modelului</i>	b_0 indică <i>valoarea medie estimată</i> a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu <i>1 unitate</i> .	
	$b_1\%$ arată cu cât <i>variază, în medie, variabila dependentă</i> (Y), atunci când variabila independentă (X) <i>crește cu 1%</i> . SAU $b_1\%$ reprezintă <i>elasticitatea (E)</i> variabilei dependente (Y) în raport cu variabila independentă (X) și arată că la o creștere a variabilei independente (X) cu <i>1%</i> , variabila dependentă (Y) variază (<i>scade</i> sau <i>crește</i> în funcție de semnul lui b_1), în medie, cu <i>$b_1\%$</i> .	
<i>Exemple din economie</i>	Analiza <i>mortalității infantile</i> (Y) în funcție de <i>Produsul Intern Brut - PIB</i> (X). Analiza relației dintre <i>salariul</i> , ca variabilă dependentă, și <i>nivelul de educație</i> , ca variabilă independentă.	

Aplicația 1

Pentru un eșantion format din 109 țări ale lumii, s-au înregistrat date pentru *mortalitatea infantilă* (decese la o mie de născuți vii) și *PIB pe locuitor* (dolari).

Tabelul *Coefficients* ne oferă rezultatele estimării și testării parametrilor modelului.

Coefficients ^a					
Model		Unstandardized Coefficients		Standardized Coefficients	t
		B	Std. Error	Beta	
1	(Constant)	8,231	,274		30,016
	lnGDP	-,628	,034	-,871	-18,337

a. Dependent Variable: lnInfant_mortality

Modelul estimat este de forma:

$$y_{x_i} = 8,231x_i^{-0,628}$$

$$\ln y_{x_i} = \ln(8,231) - 0,628 \ln x_i$$

Interpretarea estimațiilor coeficienților de regresie:

- $b_0 = 8,231$ **decese** indică nivelul mediu estimat al ratei mortalității infantile când valoarea PIB pe locuitor este egală cu **1dolari**. Evident, această valoare este una pur ipotetică.
- $b_1 = -0,628\%$ reprezintă elasticitatea mortalității infantile în raport cu PIB pe locuitor și arată că la o creștere cu **1%** a PIB/locuitor, rata mortalității infantile scade, în medie, cu **0,628%**.

Interpretarea rezultatelor testării semnificației parametrilor modelului de regresie:

Testul Student bilateral indică rezultate semnificative statistic pentru parametrii modelului, deoarece *Sigt* are valori mai mici decât riscul de 0,05. În concluzie, se consideră că între cele două variabile există o legătură (neliniară) semnificativă ce poate fi modelată cu ajutorul modelului de tip putere (sau al modelului log-liniar).

Tabelul *Model Summary* include estimația raportului de corelație și a raportului de determinație.

Model Summary				
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,871 ^a	,759	,756	,50820

a. Predictors: (Constant), lnGDP

Interpretarea estimației raportului de determinație

Observăm că estimația raportului de determinație este $R^2 = 0,759$. Acest rezultat arată că variația variabilei dependente (ratei mortalității infantile) este explicată în proporție de 75,9% de variația variabilei independente (PIB pe locuitor) prin intermediul modelului de tip putere (modelului log-liniar).

Tabelul *Anova* ne oferă rezultatele testării modelului putere.

ANOVA ^b						
Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	86,842	1	86,842	336,253	,000 ^a
	Residual	27,634	107	,258		
	Total	114,476	108			

a. Predictors: (Constant), lnGDP

b. Dependent Variable: lnInfant_mortality

Interpretarea rezultatului testării modelului (în funcție de *Sig* comparat cu riscul α)

Rezultatul testului Fisher, ce testează semnificația modelului sau a raportului de corelație, ne conduce la decizia de a respinge ipoteza nulă (care afirmă că între cele două variabile nu există o legătură semnificativă explicată de modelul de tip putere). Cu alte cuvinte, modelul de tip putere este corect specificat pentru a explica dependența neliniară dintre rata mortalității infantile și PIB pe locuitor.

1. MODELE LINIARIZABILE	1.1(b) Modelul funcției de producție (Funcția Cobb Douglas)	
	Modelul de tip putere multiplu	Modelul log-liniar multiplu
Caracterizarea modelului	Funcția de producție este un <i>model de regresie neliniară multiplă de tip log-liniar</i> , care generalizează modelul log-liniar la un număr de p variabile independente. Denumirea acestui model derivă de la utilizarea specifică a acestuia pentru a explica <i>relația dintre producție (output) și factorii principali de producție (input)</i> .	
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor	Pentru un număr de p factori sau variabile independente, modelul are următoarea formă:	
	$Y = \beta_0 X_1^{\beta_1} X_2^{\beta_2} \dots X_p^{\beta_p} e^{\varepsilon}$ $y_i = \beta_0 x_{1i}^{\beta_1} x_{2i}^{\beta_2} \dots x_{pi}^{\beta_p} e^{\varepsilon_i}$	$\ln Y = \ln \beta_0 + \beta_1 \ln X_1 + \dots + \beta_p \ln X_p + \varepsilon$ $\ln y_i = \ln \beta_0 + \beta_1 \ln x_{1i} + \dots + \beta_p \ln x_{pi} + \varepsilon_i$
	În practică, se utilizează frecvent doi factori de producție: munca (labor – L) și capitalul (K) . Modelul de regresie este următorul:	
	$Y = \beta_0 L^{\beta_1} K^{\beta_2} e^{\varepsilon}$ $y_i = \beta_0 L_i^{\beta_1} K_i^{\beta_2} e^{\varepsilon_i}$	$\ln Y = \ln \beta_0 + \beta_1 \ln L + \beta_2 \ln K + \varepsilon$ $\ln y_i = \ln \beta_0 + \beta_1 \ln L_i + \beta_2 \ln K_i + \varepsilon_i$
Restricții și observații	Variabila dependentă Y are doar valori pozitive, așadar $\beta_0 > 0$. Variabilele independente X_1 și X_2 au doar valori pozitive. Parametrii β_1 și $\beta_2 \in \mathbb{R}$, semnul indicând sensul legăturii dintre variabila dependentă și cele independente.	
Interpretarea coeficienților de regresie sau a	$\beta_0 = E(Y)_{ X_1=1 \text{ și } X_2=1}$ Parametrul β_0 reprezintă <i>media</i> variabilei dependente (Y), atunci când variabilele independente X_1 și X_2 sunt egale cu 1 unitate . Parametrul β_0 este <i>nivelul mediu al producției</i> la un input $K = 1$ și $L = 1$.	

Interpretarea coeficienților de regresie parțiali:

Parametrul β_1 reprezintă raportul dintre **variația medie relativă** a variabilei dependente și **variația relativă** a variabilei independente (X_1), în condițiile în care variabila independentă (X_2) rămâne constantă.

Parametrul β_2 reprezintă raportul dintre **variația medie relativă** a variabilei dependente și **variația relativă** a variabilei independente (X_2), în condițiile în care variabila independentă (X_1) rămâne constantă.

Exprimați în procente:

$\beta_1\%$ arată că, la o creștere a variabilei independente (X_1) cu **1%**, variabila dependentă (Y) variază, în medie, cu **$\beta_1\%$** , în condițiile în care variabila dependentă (X_2) rămâne constantă.

$\beta_2\%$ arată că, la o creștere a variabilei independente (X_2) cu **1%**, variabila dependentă (Y) variază, în medie, cu **$\beta_2\%$** , în condițiile în care influența variabilei independente (X_1) rămâne constantă.

În termeni de elasticitate:

Parametrul β_1 indică **elasticitatea parțială** a variabilei dependente (Y) în raport cu variabila independentă (X_1).

Parametrul β_1 indică **elasticitatea parțială** a producției în raport cu factorul muncă.

Parametrul β_2 reprezintă elasticitatea variabilei dependente (Y) în raport cu variabila independentă (X_2), **în condițiile în care variabila dependentă (X_1) rămâne constantă**.

Parametrul β_2 indică **elasticitatea parțială** producției în raport cu factorul capital.

Elasticitatea totală:

$(\beta_1 + \beta_2)$ reprezintă **elasticitatea totală** numită și **randament de scară** a producției. În funcție de valorile pe care le poate lua elasticitatea totală, există următoarele situații:

- $(\beta_1 + \beta_2) > 1$: **randament de scară crescător**, situație care corespunde unei variații mai accelerate a producției, în raport cu variația factorilor
- $(\beta_1 + \beta_2) < 1$: **randament de scară descrescător**, situație care corespunde unei variații mai reduse a producției (de exemplu, dacă se dublează inputul, atunci outputul crește într-o măsură mai mică, adică nu se realizează o dublare a producției)
- $(\beta_1 + \beta_2) = 1$: **randament de scară constant**, situație care corespunde unei variații constante a producției în raport cu factorii (de exemplu, dacă se dublează inputul, atunci se dublează și outputul).

<p><i>Ecuatia estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor</i></p>	$Y_X = b_0 X_1^{b_1} X_2^{b_2}$ <p>SAU</p> $Y_X = b_0 L^{b_1} K^{b_2}$ $y_{x_i} = b_0 x_{1i}^{b_1} x_{2i}^{b_2}$ <p>SAU</p> $y_{x_i} = b_0 L_i^{b_1} K_i^{b_2}$	$\ln Y_X = \ln b_0 + b_1 \ln X_1 + b_2 \ln X_2$ <p>SAU</p> $\ln Y_X = \ln b_0 + b_1 \ln L + b_2 \ln K$ $\ln y_{x_i} = \ln b_0 + b_1 \ln x_{1i} + b_2 \ln x_{2i}$ <p>SAU</p> $\ln y_{x_i} = \ln b_0 + b_1 \ln L_i + b_2 \ln K_i$
<p><i>Interpretarea estimațiilor parametrilor modelului</i></p>	<p>b_0 indică valoarea medie estimată a producției (Y), atunci când factorii muncă și capital iau valoarea 1 ($K = 1$ și $L = 1$).</p> <p>$b_1\%$ reprezintă elasticitatea parțială a producției (Y) în raport cu factorul muncă (L) și arată că la o creștere a factorului muncă (L) cu 1%, producția (Y) variază, în medie, cu $b_1\%$, în condițiile în care factorul capital (K) rămâne constant.</p> <p>$b_2\%$ reprezintă elasticitatea parțială a producției (Y) în raport cu factorul capital (K) și arată că la o creștere a factorului capital (K) cu 1%, producția (Y) variază, în medie, cu $b_2\%$, în condițiile în care factorul muncă (L) rămâne constant.</p> <p>$(b_1 + b_2)$ indică elasticitatea totală a producției (Y) în raport cu factorii muncă și capital (X_1 și X_2).</p>	
<p><i>Exemple din economie</i></p>	<p>Analiza producției (Y) în funcție de factorii de producție muncă L (X_1) și capital K (X_2).</p>	

Aplicația 2

Pentru exemplificarea modelului funcției de producție, se consideră variabila dependentă, *volum de lemn recoltat* (mii m³), și variabilele independente, *numărul mediu de salariați din sivicultură* (persoane) și *suprafața forestieră* (ha), înregistrate la nivelul județelor din România, în anul 2012.

Tabelul *Coefficients* ne oferă rezultatele estimării și testării parametrilor modelului.

Coefficients ^a						
Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	5,338	1,540		3,466	,000
	$\ln(\text{Numar_angajati})$,437	,133	,204	3,295	,002
	$\ln(\text{Suprafata_forestiera})$	1,112	,069	,999	16,160	,000

a. Dependent Variable: $\ln(\text{Volum_lemn_recoltat})$

Modelul estimat este de forma:

$$y_{x_i} = 5,338x_{1i}^{0,437}x_{2i}^{1,112}$$

$$\ln y_{x_i} = \ln(5,338) + 0,628\ln x_{1i} + 1,112\ln x_{2i}$$

SAU respectând notațiile modelului economic privind producția și factorii de producție, cele două ecuații pot fi rescrise astfel:

$$y_{x_i} = 5,338L_i^{0,437}K_i^{1,112}$$

$$\ln y_{x_i} = \ln(5,338) + 0,628\ln L_i + 1,112\ln K_i$$

Interpretarea estimațiilor punctuale ale coeficienților de regresie:

- $b_0 = 5,338$ **mii m³** indică volumul mediu estimat de lemn recoltat când numărul de salariați (L) este egal cu **1 persoană** și suprafața forestieră (K) egală cu **1 ha**;
- $b_1 = 0,437\%$ este elasticitatea **parțială** a volumului de lemn recoltat în raport cu numărul de salariați (L) și arată că la o creștere cu **1%** a numărului de salariați (L), volumul de lemn recoltat crește, în medie, cu **0,437%**, în condițiile în care suprafața forestieră (K) se menține constantă;
- $b_2 = 1,112\%$ este elasticitatea **parțială** a volumului de lemn recoltat în raport cu suprafața forestieră (K) și arată că la o creștere cu **1%** a suprafeței forestiere (K), volumul de lemn recoltat crește, în medie, cu **1,112%**, în condițiile în care numărul de salariați (L) se menține constant;
- $b_1 + b_2 = 0,437 + 1,112 = 1,549$ este elasticitatea **totală** a volumului de lemn recoltat în raport cu numărul de salariați (L) și suprafața forestieră (K) și indică **un**

randament de scară crescător ($b_1 + b_1 > 1$), adică variația producției, volumul de lemn recoltat, este mai accelerată decât variația factorilor de producție, numărul de salariați (L) și suprafața forestieră (K).

Interpretarea rezultatelor testării semnificației parametrilor modelului de regresie:

Testul Student bilateral indică estimații semnificative statistic pentru parametrii modelului, deoarece $Sigt = P(> |t|)$ are valori mai mici decât pragul de 0,05:

- semnificația coeficientului parțial de regresie β_1 arată că numărul de salariați are o influență neliniară parțială semnificativă asupra variației volumului de lemn recoltat;
- semnificația coeficientului parțial de regresie β_2 arată că suprafața forestieră are o influență neliniară parțială semnificativă asupra variației volumului de lemn recoltat.

Tabelul *Model Summary* ne prezintă estimațiile raportului de corelație multiplă și a raportului de determinație multiplă.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,937 ^a	,878	,871	,33881

a. Predictors: (Constant), lnSuprafata_forestiera, lnNumar_angajati

Estimația raportului de determinație multiplă arată că variația variabilei dependente (volumul de lemn recoltat) este explicată de variația simultană a factorilor de producție (numărul de salariați și suprafața forestieră) în proporție de 87,8%, variație explicată cu ajutorul modelului log-liniar multiplu sau al funcției de producție.

Tabelul *Anova* ne oferă rezultatele testării modelului de tip putere multiplu.

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	31,339	2	15,669	136,503	,000 ^a
	Residual	4,362	38	,115		
	Total	35,701	40			

a. Predictors: (Constant), lnSuprafata_forestiera, lnNumar_angajati

b. Dependent Variable: lnVolum_lemn_recultat

Testul Fisher ne arată că modelul funcției de producție este semnificativ statistic ($Sigt < 0,05$) și explică dependența dintre volumul de lemn recoltat și factorii considerați: numărul de salariați și suprafața forestieră.

Modele semi-logaritmice (1)

Modelele semi-logaritmice sunt modele neliniare în care fie variabila independentă, fie variabila dependentă apare ca variabilă logaritmată.

Aceste modele sunt construite, de regulă, cu scopul de a estima variația *relativă* sau *absolută* a variabilei dependente la o variație *absolută* sau *relativă* a variabilei independente.

1. MODELE LINIARIZABILE	1.2. Modelul semi-logaritmice cu variabila independentă (X) logaritmată (Logarithmic)	
	Modelul Logarithmic	Modelul lin-log (liniarizat)
Reprezentarea grafică		
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoare a variabilelor	$Y = \beta_0 + \beta_1 \ln X + \varepsilon$ $y_i = \beta_0 + \beta_1 \ln x_i + \varepsilon_i$	
Restricții și observații	Variabila independentă X are doar valori pozitive. Parametrul $\beta_1 \in \mathbb{R}$, semnul indicând sensul legăturii dintre cele două variabile.	
Interpretarea coeficienților de regresie sau a parametrilor modelului	$\beta_0 = E(Y)_{ X=1} \Leftrightarrow \beta_0 = E(Y)_{ \ln X=0}$ <p>Parametrul β_0 indică <i>valoarea medie</i> a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 1 unitate.</p>	
	$\beta_1 = \frac{dY}{d\ln X} = \frac{dY}{\frac{dX}{X}} = \frac{dY}{dX} X$ <p>Parametrul β_1 exprimă <i>variația absolută medie</i> a variabilei dependente (Y) la o <i>modificare relativă</i> cu o unitate a variabilei independente X.</p>	

	<p>Pentru parametrul β_1 din acest model, în interpretare, trebuie să se țină cont de faptul că variabila dependentă înregistrează o variație absolută, iar variabila independentă o variație relativă sau o variație cu o unitate în logaritmi. Pentru exprimarea procentuală, este nevoie de o împărțire a acestui coeficient cu 100:</p> $\frac{\beta_1}{100} = dY_{ d\ln X=1\%}$ <p>$\beta_1/100$ arată că, la o creștere a variabilei independente (X) cu 1%, variabila dependentă (Y) variază, în medie, cu $\beta_1/100$ unități (unitatea de măsură a lui Y).</p>
<i>Ecuția estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor</i>	$Y_X = b_0 + b_1 \ln X$ $y_{x_i} = b_0 + b_1 \ln x_i$
<i>Interpretarea estimațiilor parametrilor modelului</i>	<p>b_0 indică valoarea medie estimată a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 1 unitate.</p> <p>$b_1/100$ arată cu cât variază, în medie, variabila dependentă (Y), atunci când variabila independentă (X) crește cu 1%.</p>
<i>Exemple din economie</i>	<p>Analiza Ratei mortalității infantile (Y) în funcție de Produsul Intern Brut - PIB (X).</p> <p>Analiza legăturii dintre puterea motorului (Y) și numărul de cilindri (X).</p>

Aplicația 3

Pentru un eșantion format din 109 țări ale lumii, s-au înregistrat date pentru *mortalitatea infantilă* (decese la o mie de născuți vii) și *PIB/locuitor* (dolari).

Tabelul *Coefficients* ne oferă rezultatele estimării și testării parametrilor modelului.

Coefficients ^a					
Model		Unstandardized Coefficients		Standardized Coefficients	Sig.
		B	Std. Error	Beta	
1	(Constant)	215,381	11,709		,000
	lnGDP	-21,966	1,462	-,824	,000

a. Dependent Variable: Infant mortality (deaths per 1000 live births)

Modelul estimat este de forma:

$$Y_X = 215,381 - 21,966 \ln X$$

$$y_{x_i} = 215,381 - 21,966 \ln x_i$$

Interpretarea estimațiilor punctuale ale coeficienților de regresie ai modelului:

- $b_0 = 215,381$ decese ne indică nivelul mediu estimat al ratei mortalității infantile, atunci când valoarea PIB este egală cu 1 dolar pe locuitor. Evident, această valoare este una pur ipotetică.
- $b_1/100 = -21,966/100 = -0,219$ decese arată că la o creștere cu 1% a PIB/locuitor, rata mortalității infantile scade, în medie, cu 0,219 decese.

Interpretarea rezultatelor testării semnificației parametrilor modelului de regresie:

Testul Student bilateral indică estimații semnificative statistic pentru parametrii modelului, deoarece $Sigt = P(> |t|)$ are valori mai mici decât pragul de 0,05. În concluzie, se consideră că între cele două variabile există o legătură (neliniară) semnificativă ce poate fi modelată cu ajutorul modelului logarithmic.

Tabelul *Model Summary* ne prezintă estimația raportului de corelație și a raportului de determinație.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,824 ^a	,678	,675	21,6996

a. Predictors: (Constant), lnGDP

Rezultatele de mai sus indică o legătură (neliniară) puternică între cele două variabile. Raportul de determinație este de 0,678, adică putem spune că, prin intermediul modelului logaritm, variația ratei mortalității infantile este explicată în proporție de 67,8% de variația PIB/locuitor.

Tabelul *Anova* ne oferă rezultatele testării modelului logaritm.

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	106219,4	1	106219,443	225,579	,000 ^a
	Residual	50383,514	107	470,874		
	Total	156603,0	108			

a. Predictors: (Constant), lnGDP

b. Dependent Variable: Infant mortality (deaths per 1000 live births)

Conform testului Fisher, raportul de determinație este semnificativ statistic, cu o probabilitate de 0,95 (probabilitatea asociată testului, *Sigt*, este mai mică de 0,05). În concluzie, legătura dintre mortalitatea infantilă și PIB explicată prin intermediul modelului logaritm este semnificativă statistic.

Modele semi-logaritmice (2)

Modelele semi-logaritmice cu variabila dependentă transformată prin funcția logaritm sunt construite pentru studiul legăturii dintre variabile prin utilizarea modelelor matematice de tipul funcțiilor exponențiale.

Aceste modele se pot utiliza în practică pentru a estima modificările relative medii ale variabilei dependente la o modificare absolută cu o unitate a variabilei independente. În funcție de expresia matematică a modelului, se întâlnesc mai multe exemple de asemenea modele semi-logaritmice.

1. MODELE LINIARIZABILE	1.3(a) Modele semi-logaritmice cu variabila dependentă (Y) logaritmată	
	Modelul compus (Compound)	Modelul log-lin (liniarizat)
Reprezentarea grafică		
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor	Considerăm modelul de regresie de forma: $Y = \beta_0 \beta_1^X e^\varepsilon$ $y_i = \beta_0 \beta_1^{x_i} e^{\varepsilon_i}$	Prin logaritmare, se obține modelul: $\ln Y = \ln \beta_0 + \ln \beta_1 X + \varepsilon$ $\ln y_i = \ln \beta_0 + \ln \beta_1 x_i + \varepsilon_i$ <p>Se observă că acest model este unul liniar în care doar variabila dependentă apare logaritmată, deci este un model liniar semi-logaritm.</p>
Restricții și observații	Variabila dependentă Y are doar valori pozitive, așadar $\beta_0 > 0$. Parametrul β_1 , fiind logaritmat, nu poate lua decât valori pozitive: <ul style="list-style-type: none">- dacă $\beta_1 > 1$ ($\ln \beta_1 > 0$), adică supraunitar, atunci legătura dintre cele două variabile este directă (pozitivă).- dacă $0 < \beta_1 < 1$ ($\ln \beta_1 < 0$), adică subunitar, atunci legătura dintre cele două variabile este inversă (negativă).	
Interpretarea coeficienților de regresie sau a	$\beta_0 = E(Y)_{ X=0}$ Parametrul β_0 indică valoarea medie a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.	

<p><i>parametrilor modelului</i></p>	$\ln\beta_1 = \frac{d\ln Y}{dX} = \frac{\frac{dY}{Y}}{\frac{dX}{X}} = \frac{dY}{dX} \frac{1}{Y}$ <p>Parametrul β_1 nu are interpretare directă, ci interpretăm $\ln\beta_1$. $\ln\beta_1$ exprimă variația medie relativă (modificarea medie procentuală) a variabilei dependente (Y) la o variație absolută cu o unitate a variabilei independente X.</p> <p>Pentru parametrul β_1 din acest model, în interpretare, trebuie să se țină cont de faptul că variabila dependentă înregistrează o variație relativă, iar variabila independentă o variație absolută. Pentru exprimarea procentuală, este nevoie de o înmulțire a $\ln\beta_1$ cu 100:</p> $\ln\beta_1 = d\ln Y _{dX=1} \Leftrightarrow \ln\beta_1 \cdot 100\% = d\ln Y_{(\%)} _{dX=1}$ <p>Interpretat procentual, $\ln\beta_1 \cdot 100\%$ arată că la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă (Y) variază, în medie, cu $\ln\beta_1 \cdot 100\%$. De asemenea, $\ln\beta_1 \cdot 100\%$ reprezintă rata de creștere a variabilei Y în raport cu variabila X.</p>	
<p><i>Ecuția estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor</i></p>	$Y_X = b_0 b_1^X$ $y_{x_i} = b_0 b_1^{x_i}$	$\ln Y_X = \ln b_0 + \ln b_1 \ln X$ $\ln y_{x_i} = \ln b_0 + \ln b_1 x_i$
<p><i>Interpretarea estimațiilor parametrilor modelului</i></p>	<p>b_0 indică valoarea medie estimată a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.</p> <p>$[(\ln b_1) \cdot 100]\%$ arată că, la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă variază, în medie, cu $[(\ln b_1) \cdot 100]\%$. $[(\ln b_1) \cdot 100]\%$ reprezintă rata de creștere a variabilei dependente (Y) în raport cu variabila independentă (X).</p>	
<p><i>Exemple din economie</i></p>	<p>Analiza legăturii dintre <i>valoarea producției</i> (Y) și <i>valoarea investițiilor</i> (X).</p>	

Modelul compus

Aplicația 4

În urma analizei legăturii dintre *Produsul Intern Brut* (euro) și *Rata inflației* (%), înregistrate pentru țările Uniunii Europene, s-au obținut următoarele rezultate:

Coefficients(a)

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	20140,640	,212		46,639	,000
	Rata inflației (%)	1,002	,042	,451	23,457	,000

a Dependent Variable: \ln PIB

Modelul estimat este de forma:

$$y_{x_i} = 20140,64 \cdot 1,002^{x_i}$$

$$\ln y_{x_i} = \ln(20140,64) + \ln(1,002) \cdot x_i$$

Interpretarea estimațiilor punctuale ale coeficienților de regresie:

- $b_0 = 20140,64$ euro indică nivelul mediu estimat al PIB-ului atunci când rata inflației este egală cu 0% (atenție: % este unitatea de măsură a ratei inflației).
- $[(\ln b_1) \cdot 100]\% = [(\ln(1,002)) \cdot 100]\%$ este rata de creștere a PIB-ului în raport cu rata inflației și arată că la o creștere cu 1% (atenție: % este unitatea de măsură a ratei inflației) a ratei inflației, PIB-ul crește, în medie, cu $[(\ln(1,002)) \cdot 100]\%$.

Model Summary

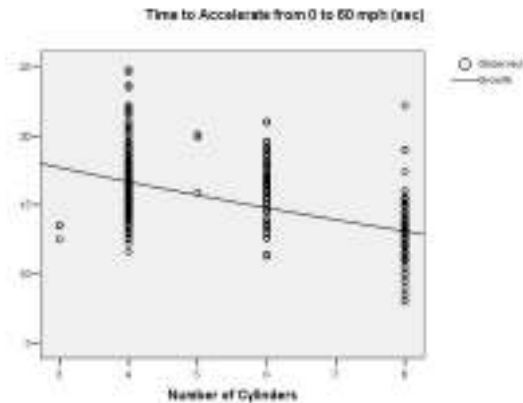
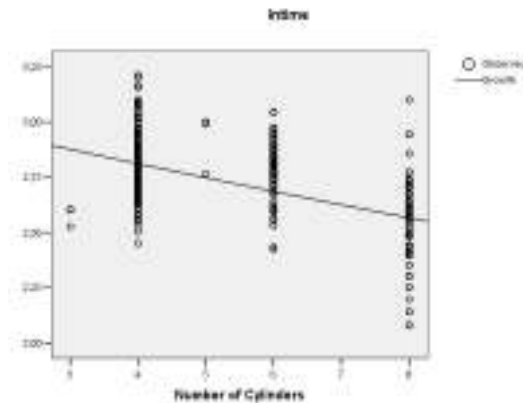
Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,004(a)	,000	-,038	,64892

a Predictors: (Constant), Rata inflației (%)

ANOVA(b)

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	4,439	1	4,439	54,806	,000(a)
	Residual	10,949	26	,081		
	Total	15,388	27			

a Predictors: (Constant), Rata inflației (%)

1. MODELE LINIARIZABILE	1.3(b) Modele semi-logaritmice cu variabila dependentă (Y) logaritmată	
	Modelul de creștere (<i>Growth</i>)	Modelul log-lin (liniarizat)
Reprezentarea grafică		
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoare a variabilelor	<p>Considerăm modelul de regresie de forma:</p> $Y = e^{\beta_0 + \beta_1 X + \varepsilon}$ $y_i = e^{\beta_0 + \beta_1 x_i + \varepsilon_i}$	<p>Prin logaritmare, se obține modelul:</p> $\ln Y = \beta_0 + \beta_1 X + \varepsilon$ $\ln y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$
Restricții și observații	<p>Variabila dependentă Y are doar valori pozitive, însă β_0 poate lua și valori negative. Parametrul $\beta_1 \in \mathbb{R}$, semnul indicând sensul legăturii dintre cele două variabile.</p>	
Interpretarea coeficienților de regresie sau a parametrilor modelului	<p>Parametrul β_0 nu are interpretare directă, ci interpretăm e^{β_0}.</p> $e^{\beta_0} = M(Y)_{ X=0}$ <p>e^{β_0} indică valoarea medie a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.</p>	
	$\beta_1 = \frac{d \ln Y}{dX} = \frac{\frac{dY}{Y}}{dX} = \frac{dY}{dX} \frac{1}{Y}$ <p>Parametrul β_1 exprimă variația medie relativă (modificarea medie procentuală) a variabilei dependente (Y) la o variație absolută cu o unitate a variabilei independente X.</p>	

	<p>Pentru parametrul β_1 din acest model, în interpretare, trebuie să se țină cont de faptul că variabila dependentă înregistrează o variație relativă. Pentru exprimarea procentuală, este nevoie de o înmulțire a acestui coeficient β_1 cu 100:</p> $\beta_1 = d\ln Y _{dX=0} \Leftrightarrow \beta_1 \cdot 100\% = d\ln Y_{(\%)} _{dX=0}$ <p>Interpretat procentual, $\beta_1 \cdot 100\%$ arată că la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă (Y) variază, în medie, cu $\beta_1 \cdot 100\%$.</p> <p>De asemenea, $\beta_1 \cdot 100\%$ reprezintă rata de creștere a variabilei Y în raport cu variabila X.</p>	
Ecuția estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor	$Y_X = e^{b_0 + b_1 X}$ $y_{x_i} = e^{b_0 + b_1 x_i}$	$\ln Y_X = b_0 + b_1 X$ $\ln y_{x_i} = b_0 + b_1 x_i$
Interpretarea estimațiilor parametrilor modelului	<p>e^{b_0} indică valoarea medie estimată a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.</p>	
	<p>$(b_1 \cdot 100)\%$ arată că, la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă variază, în medie, cu $(b_1 \cdot 100)\%$.</p> <p>$(b_1 \cdot 100)\%$ reprezintă rata de creștere a variabilei dependente (Y) în raport cu variabila independentă (X).</p>	
Exemple din economie	<p>Analiza legăturii dintre <i>valoarea producției</i> (Y) și <i>valoarea investițiilor</i> (X).</p>	

Modelul de creștere

Aplicația 5

Se consideră legătura dintre *Timpul de accelerare de la 0 la 100 km/h* (secunde) și *Număr de cilindri*.

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	3,054	,026		118,715	,000
	Number of Cylinders	-,060	,004	-,556	-13,413	,000

a. Dependent Variable: lntime

Modelul estimat este de forma:

$$y_{x_i} = e^{3,054 - 0,060 \cdot x_i}$$

$$\ln y_{x_i} = 3,054 - 0,060 \cdot x_i$$

Interpretarea estimațiilor punctuale ale coeficienților de regresie:

- $e^{b_0} = e^{3,054}$ **secunde** indică nivelul mediu estimat al timpului de accelerare atunci când numărul de cilindri este egal cu **0 cilindri**.
- $[b_1 \cdot 100]\% = [-0,060 \cdot 100]\%$ este rata de creștere a timpului de accelerare în raport cu numărul de cilindri și arată că la o creștere cu **1 cilindru** a numărului de cilindri, timpul de accelerare scade, în medie, cu **6%**.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,556 ^a	,309	,307	,15431

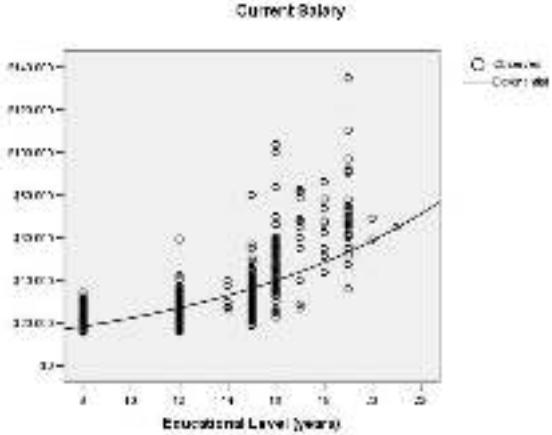
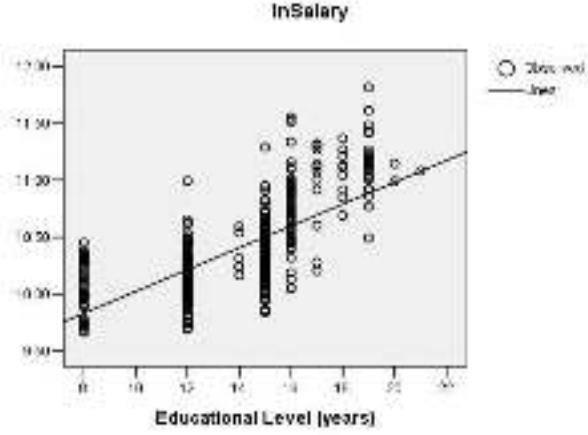
a. Predictors: (Constant), Number of Cylinders

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	4,284	1	4,284	179,898	,000 ^a
	Residual	9,596	403	,024		
	Total	13,879	404			

a. Predictors: (Constant), Number of Cylinders

b. Dependent Variable: Intime

1. MODELE LINIARIZABILE	1.3(c) Modele semi-logaritmice cu variabila dependentă (Y) logaritmată	
	Modelul exponențial (<i>Exponential</i>)	Modelul log-lin (liniarizat)
<i>Reprezentarea grafică</i>		
<i>Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor</i>	<p>Considerăm modelul de regresie de forma:</p> $Y = \beta_0 e^{\beta_1 X} e^{\varepsilon}$ $y_i = \beta_0 e^{\beta_1 x_i} e^{\varepsilon_i}$	<p>Prin logaritmare, se obține modelul:</p> $\ln Y = \ln \beta_0 + \beta_1 X + \varepsilon$ $\ln y_i = \ln \beta_0 + \beta_1 x_i + \varepsilon_i$
<i>Restricții și observații</i>	<p>Variabila dependentă Y are doar valori pozitive, așadar $\beta_0 > 0$. Parametrul $\beta_1 \in \mathbb{R}$, semnul indicând sensul legăturii dintre cele două variabile.</p>	
<i>Interpretarea coeficienților de regresie sau a parametrilor modelului</i>	<p>$\beta_0 = E(Y) _{X=0}$</p> <p>Parametrul β_0 indică valoarea medie a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.</p> $\beta_1 = \frac{d \ln Y}{dX} = \frac{\frac{dY}{Y}}{\frac{dX}{dX}} = \frac{dY}{dX} \frac{1}{Y}$ <p>Parametrul β_1 exprimă variația medie relativă (modificarea medie procentuală) a variabilei dependente (Y) la o variație absolută cu o unitate a variabilei independente X.</p>	

	<p>Pentru parametrul β_1 din acest model, în interpretare, trebuie să se țină cont de faptul că variabila dependentă înregistrează o variație relativă. Pentru exprimarea procentuală, este nevoie de o înmulțire a acestui coeficient β_1 cu 100:</p> $\beta_1 = d\ln Y _{dX=0} \Leftrightarrow \beta_1 \cdot 100\% = d\ln Y_{(\%)} _{dX=0}$ <p>Interpretat procentual, $\beta_1 \cdot 100\%$ arată că la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă (Y) variază, în medie, cu $\beta_1 \cdot 100\%$.</p> <p>De asemenea, $\beta_1 \cdot 100\%$ reprezintă rata de creștere a variabilei dependente Y în raport cu variabila independentă X.</p>	
<i>Ecuția estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor</i>	$Y_X = b_0 e^{b_1 X}$ $y_{x_i} = b_0 e^{b_1 x_i}$	$\ln Y_X = \ln b_0 + b_1 \ln X$ $\ln y_{x_i} = \ln b_0 + b_1 x_i$
<i>Interpretarea estimațiilor parametrilor modelului</i>	<p>b_0 indică valoarea medie estimată a variabilei dependente (Y), atunci când variabila independentă (X) este egală cu 0.</p>	
	<p>$(b_1 \cdot 100)\%$ arată că, la o creștere cu 1 unitate a variabilei independente (X), variabila dependentă variază, în medie, cu $(b_1 \cdot 100)\%$.</p> <p>$(b_1 \cdot 100)\%$ reprezintă rata de creștere a variabilei dependente (Y) în raport cu variabila independentă (X).</p>	
<i>Exemple din economie</i>	<p>Analiza legăturii dintre <i>valoarea producției</i> (Y) și <i>valoarea investițiilor</i> (X).</p>	

Modelul exponențial

Aplicația 6

Pentru a exemplifica modelul de regresie exponențial, se consideră variabilele *Current salary* (dolari), ca variabilă dependentă, și *Education level* (ani), ca variabilă independentă.

Coefficients(a)					
Model		Unstandardized Coefficients		Standardized Coefficients	t
		B	Std. Error	Beta	
1	(Constant)	8622,253	,063		144,445
	Education level (years)	,096	,005	,697	21,102

a. Dependent Variable: \ln salary

Modelul estimat este de forma:

$$y_{x_i} = 8622,253 \cdot e^{0,096 \cdot x_i}$$

$$\ln y_{x_i} = \ln(8622,253) + 0,096 \cdot x_i$$

Interpretarea estimațiilor punctuale ale coeficienților de regresie:

- $b_0 = 8622,253$ dolari indică nivelul mediu estimat al salariului atunci când nivelul de educație este egal cu 0 ani.
- $[b_1 \cdot 100]\% = [0,096 \cdot 100]\%$ este rata de creștere a salariului în raport cu nivelul de educație și arată că la o creștere cu 1 an a nivelului de educație, salariul crește, în medie, cu 9,6%.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,697 ^a	,485	,484	,28532

a. Predictors: (Constant), Educational Level (years)

ANOVA^b

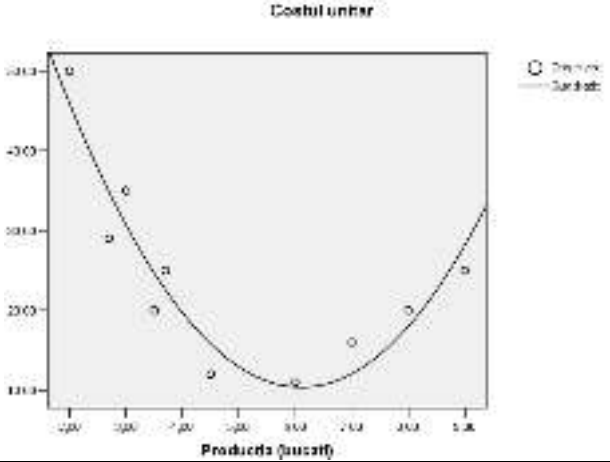
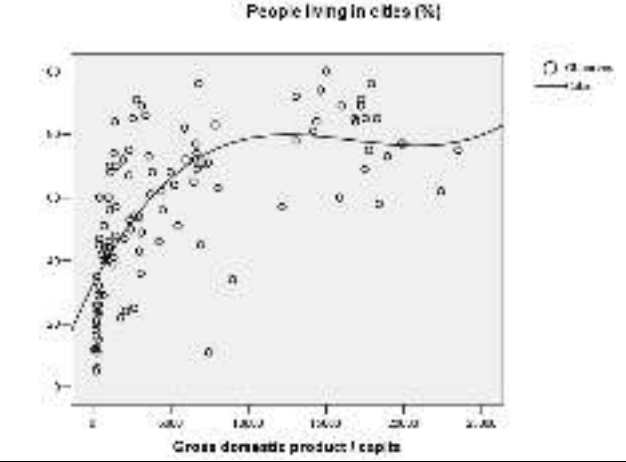
Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	36,251	1	36,251	445,300	,000 ^a
	Residual	38,424	472	,081		
	Total	74,675	473			

a. Predictors: (Constant), Educational Level (years)

b. Dependent Variable: \ln salary

4.3. Modele polinomiale

Modelele polinomiale sunt modele de regresie neliniară care admit o legătură între variabila dependentă și cea independentă ce poate fi explicată printr-o funcție polinomială de grad mai mare sau egal cu doi.

2. MODELE NELINIARIZABILE	Modele polinomiale	
	2.1. Modelul parabolic (Quadratic)	2.2. Modelul cubic
Reprezentarea grafică		
Interpretarea grafică	Graficul arată că între <i>costul unitar de producție</i> și <i>producția</i> firmei există o legătură de tip parabolic cu un punct de minim. Cu alte cuvinte, parabola admite un punct de minim.	Graficul ne indică o legătură cubică între cele două variabile. Odată cu creșterea <i>gradului de dezvoltare economică</i> , crește și <i>ponderea populației urbane</i> a acelei țări. Continuarea creșterii economice poate determina și un ușor fenomen de scădere a gradului de urbanizare, prin fenomenul de migrație spre zonele rurale din preajma marilor aglomerări urbane. Creșterea economică poate antrena urbanizarea prin cooptarea acestor regiuni în zonele metropolitane.
Forma generală a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoarea a variabilelor	Modelul parabolic are la bază o funcție polinomială de gradul doi și are forma: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$ $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \varepsilon_i$	Modelul cubic are la bază o funcție polinomială de gradul trei și are forma: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \varepsilon$ $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \varepsilon_i$

Interpretarea coeficienților de regresie sau a parametrilor modelului	<p>Pentru identificarea punctului de extrem și a tipului de curbă (convexă sau concavă), se utilizează condițiile matematice specifice ecuației de gradul 2.</p> <p>Coordonatele punctului critic</p> <ul style="list-style-type: none"> - abscisa: $x_i = -\beta_1/2\beta_2$ - ordonata: y_{x_i} 	<p>Pe baza acestei ecuații, se pot determina abscisele pentru trei puncte importante ale curbei ce explică dependența dintre variabile.</p> <p>Coordonatele punctului de inflexiune</p> <ul style="list-style-type: none"> - abscisa: $x_i = -\frac{2\beta_2}{6\beta_3} \Rightarrow x_i = -\beta_2/3\beta_3$ - ordonata: y_{x_i}
Ecuația estimată a modelului scrisă pentru toate valorile variabilelor și pentru fiecare valoare a variabilelor	$Y_X = b_0 + b_1X + b_2X^2$ $y_{x_i} = b_0 + b_1x_i + b_2x_i^2$	$Y_X = b_0 + b_1X + b_2X^2 + b_3X^3$ $y_{x_i} = b_0 + b_1x_i + b_2x_i^2 + b_3x_i^3$
Interpretarea estimațiilor parametrilor modelului	<p>Se obține soluția derivatei întâi:</p> $y'_{x_i} = 0$, adică $b_1 + 2b_2x_i = 0$ <ul style="list-style-type: none"> - abscisa: $x_i = -b_1/2b_2$ - ordonata: y_{x_i} (înlocuim valoarea x_i în ecuația estimată) <p>Se pune condiția de extrem:</p> <ul style="list-style-type: none"> - $y''_{x_i} > 0$ sau $b_2 > 0$, pentru punct de minim - $y''_{x_i} < 0$ sau $b_2 < 0$, pentru punct de maxim 	<p>Coordonatele celor două puncte de extrem, ca soluții ale ecuației:</p> $y'_{x_i} = 0$, adică $b_1 + 2b_2x_i + 3b_3x_i^2 = 0$ <ul style="list-style-type: none"> - abscisa: x_i - ordonata: y_{x_i} (înlocuim valoarea x_i în ecuația estimată) <p>Coordonatele punctului de inflexiune, ca soluție a ecuației:</p> $y''_{x_i} = 0$, adică $2b_2 + 6b_3x_i = 0$ <ul style="list-style-type: none"> - abscisa: $x_i = -b_2/3b_3$ - ordonata: y_{x_i} (înlocuim valoarea x_i în ecuația estimată)
Exemple din economie	<p>Modelul parabolic se pretează la acele aplicații economice care presupun o schimbare în variația variabilei dependente la o anumită valoare critică a variabilei independente ce corespunde unui punct de extrem (de minim sau de maxim).</p> <p>Un exemplu este costului unitar al producției (Y) în relație cu valoarea producției (X).</p>	<p>Modelul cubic este utilizat pentru a aprecia evoluții mai complexe ale unor realități economice.</p> <p>Un exemplu tipic întâlnit este costul total (Y) care depinde de valoarea producției (X).</p>

Aplicația 7

În studiul legăturii dintre *costul unitar* (unități monetare) și *producția unui bun* (bucăți), înregistrate pentru un eșantion de firme, s-au obținut următoarele rezultate:

Coefficients^a

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.
	B	Std. Error	Beta		
1 (Constant)	89,041	9,231		9,646	,000
Productia	-25,795	3,895	-5,322	-6,623	,000
Productia**2	2,114	,351	4,842	6,026	,001

a. Dependent Variable: Costul unitar

Modelul estimat este de forma:

$$Y_X = 89,041 - 25,795 \cdot X + 2,114 \cdot X^2$$

Coordonatele punctului critic:

- **abscisa:**

$$x_i = -b_1 / 2b_2 = 6,1 \text{ bucăți}$$

- **ordonata:**

$$y_{x_i} = 89,041 - 25,795 \cdot x_i + 2,114 \cdot x_i^2 = 10,35 \text{ unități monetare}$$

Interpretarea punctului critic:

Punctul critic de minim corespunde unei *producții optime de 6,1 bucăți* din produsul, producție pentru care *costul unitar de 10,35 unități monetare* este *minim*.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,699 ^a	,488	,474	17,559

a. Predictors: (Constant), Gross domestic product / capita

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	30615,972	3	10205,324	33,100	,000 ^a
	Residual	32064,944	104	308,317		
	Total	62680,917	107			

a. Predictors: (Constant), Gross domestic product / capita

b. Dependent Variable: People living in cities (%)

Aplicația 8

Se consideră *Gradul de urbanizare* (procentul populației urbane dintr-o țară), variabila dependentă, și *PIB/locuitor* (dolari), variabilă independentă, înregistrate pentru 195 de țări.

Coefficients(a)

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.
	B	Std. Error	Beta		
1 (Constant)	32,036	,002	2,557	4,950	,000
GDP	1,002	,000	-3,206	-2,652	,009
GDP**2	-6,1E-007	,000	1,225	.	.
GDP**3	1,21E-011	3,395		9,438	,000

The independent variable is Gross domestic product/capita.

Modelul estimat este de forma:

$$Y_X = 32,036 + 1,002 \cdot X - 6,1 \cdot 10^{-7} \cdot X^2 + 1,21 \cdot 10^{-11} \cdot X^3$$

Coordonatele punctului de inflexiune:

- abscisa:

$$x_i = -b_2/3b_3 = 6,1 \cdot 10^{-7} / 3 \cdot 1,21 \cdot 10^{-11} = 1,68 \cdot 10^4$$

- ordonata:

$$y_{x_i} = 32,036 + 1,002 \cdot x_i - 6,1 \cdot 10^{-7} \cdot x_i^2 + 1,21 \cdot 10^{-11} \cdot x_i^3$$

Interpretarea punctului de inflexiune:

Modelul poate fi util pentru realizarea de predicții privind nivelului de urbanizare al unei țări în funcție de un anumit grad de dezvoltare economică sau poate permite estimarea unei anumite valori a nivelului de dezvoltare necesară pentru a putea atinge un nivel mediu de urbanizare dorit.

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,699 ^a	,488	,474	17,559

a. Predictors: (Constant), Gross domestic product / capita

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	30615,972	3	10205,324	33,100	,000 ^a
	Residual	32064,944	104	308,317		
	Total	62680,917	107			

a. Predictors: (Constant), Gross domestic product / capita

b. Dependent Variable: People living in cities (%)